

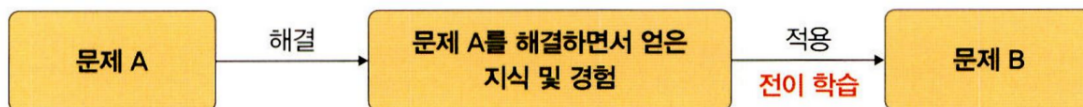


Week 4_예습과제_김정은

전이 학습

- 큰 데이터 셋을 얻지 못하는 현실적인 어려움을 해결한 것 → 전이 학습.
 - 이미지넷처럼 아주 큰 데이터셋을 써서 훈련된 모델의 가중치를 가져와 해결하려는 과제에 맞게 보정해서 사용
 - 아주 큰 데이터셋을 사용하여 훈련된 모델 → 사전 훈련된 모델(네트워크)

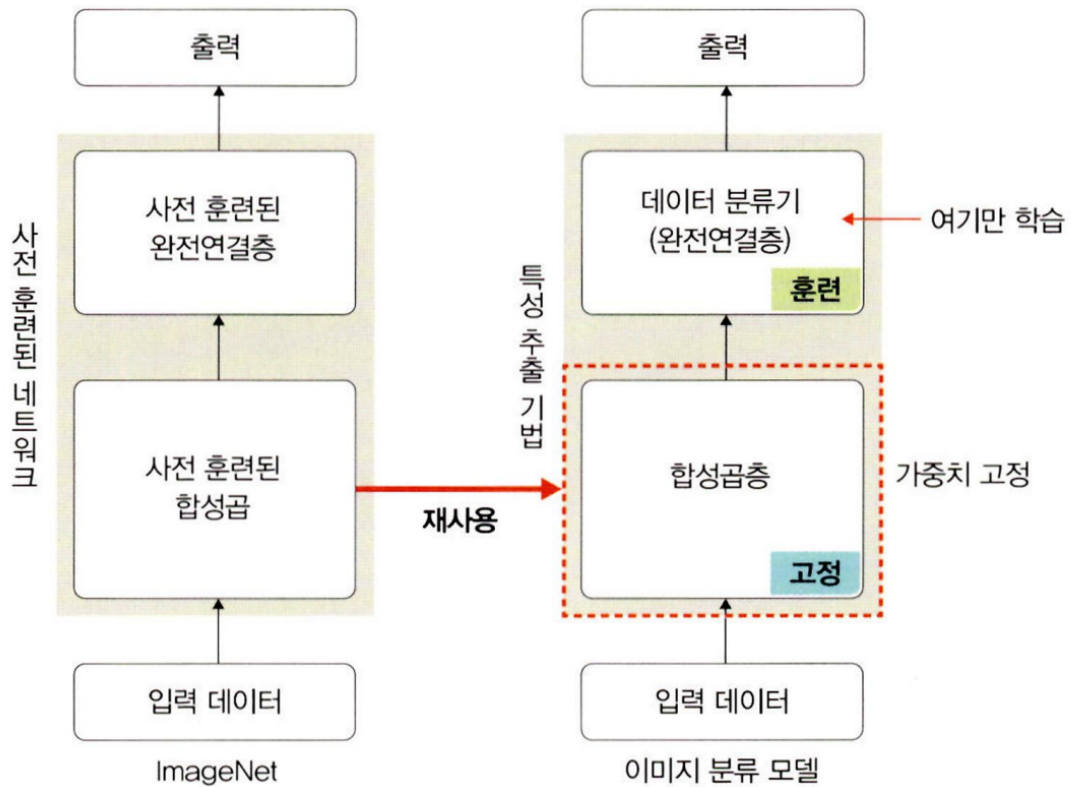
▼ 그림 5-29 전이 학습



특성 추출 기법

- ImageNet 데이터셋으로 사전 훈련된 모델을 가져온 후 마지막에 완전연결층 부분만 새로 만든다.
- 학습할 때는 마지막 완전연결층(이미지의 카테고리를 결정)만 학습 → 나머지 계층 학습 X
- 목표 특성을 잘 추출했다는 전제 하에 좋은 성능을 낼 수 있음
- 특성 추출
 - 합성곱층 : 합성곱층과 풀링층으로 구성
 - 데이터 분류기(완전연결층) : 추출된 특성을 입력받아 최종적으로 이미지에 대한 클래스를 분류
 - 사전 훈련된 네트워크의 합성곱층(가중치 고정)에 새로운 데이터를 통과시키고, 그 출력을 데이터 분류기에서 훈련시킨다.


▼ 그림 5-30 특성 추출 기법



계산 그래프

- 계산 과정을 그래프로 나타낸 것
- 여러 개의 노드와 그 노드를 연결하는 선인 에지(edge)로 구성됨
- 국소적 계산이 가능하다는 장점
- 역전파를 통한 미분 계산이 편리

▼ 그림 5-39 계산 그래프



연쇄 법칙

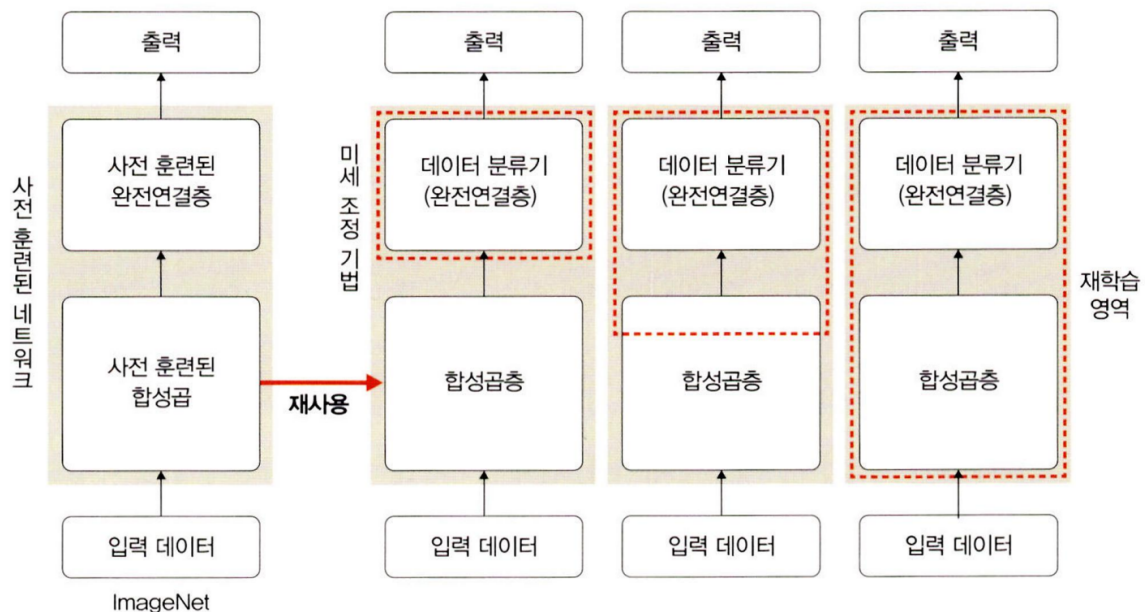
- 두 개 이상의 함수가 결합된 함수, 합성 함수의 미분법을 연쇄 법칙 혹은 체인 룰(Chain Rule)

미세 조정 기법

- 특성 추출 기법에서 더 나아가 사전 훈련된 모델과 합성곱층, 데이터 분류기의 가중치를 업데이트하여 훈련시키는 방식
- 특성이 잘못 추출되었다면 미세 조정 기법으로 새로운 이미지 데이터를 사용하여 네트워크의 가중치를 업데이트해서 특성을 다시 추출할 수 있음
- 사전 학습된 모델을 목적에 맞게 재학습시키거나 학습된 가중치의 일부를 재학습
- 사전 훈련된 네트워크를 미세 조정하여 분석하려는 데이터셋에 잘 맞도록 모델의 파라미터를 조정. 많은 연산량 필요 → GPU 사용을 권장
- 데이터셋이 크고 사전 훈련된 모델과 유사성이 작을 경우 : 모델 전체를 재학습.

- 데이터셋이 크고 사전 훈련된 모델과 유사성이 클 경우 : 합성곱층의 뒷부분과 데이터 분류기를 학습. 데이터셋이 유사하기 때문에 전체를 학습시키는 것보다는 강한 특징이 나타나는 합성곱층의 뒷부분과 데이터 분류기만 새로 학습하더라도 최적의 성능 가능
- 데이터셋이 작고 사전 훈련된 모델과 유사성이 작을 경우 : 합성곱층의 일부분과 데이터 분류기를 학습. 데이터가 적기 때문에 일부 계층에 미세 조정 기법을 적용한다고 해도 효과가 없을 수 있음.
- 데이터셋이 작고 사전 훈련된 모델과 유사성이 클 경우 : 데이터 분류기만 학습. 데이터가 적기 때문에 많은 계층에 미세 조정 기법을 적용하며 과적합 발생 가능성. → 최종 데이터 분류기인 완전연결층에 대해서만 미세 조정 기법 적용

♥ 그림 5-44 미세 조정 기법



설명 가능한 CNN

- 딥러닝 처리 결과를 사람이 이해할 수 있는 방식으로 제시하는 기술
- CNN 처리 과정을 시각화해야 할 필요성
- CNN을 구성하는 각 중간 계층부터 최종 분류까지 입력된 이미지에서 특성이 어떻게 추출되고 학습하는지를 시각적으로 설명할 수 있어야 결과에 대한 신뢰성을 얻을 수 있음

특성 맵 시각화

- 특성 맵(혹은 활성화 맵)은 입력 이미지 또는 다른 특성 맵처럼 필터를 입력에 적용한 결과
- 특정 입력 이미지에 대한 특성 맵을 시각화 → 특성 맵에서 입력 특성을 감지하는 방법을 이해할 수 있도록 돕는 것
- PIL → 이미지 분석 및 처리를 쉽게 할 수 있도록 도와주는 라이브러리
 - 다양한 이미지 파일 형식 지원
 - 강력한 이미지 처리와 그래픽 기능을 제공, 이미지 프로세싱 라이브러리
- 로그 소프트맥스 → 신경망 말단의 결괏값들을 확률 개념으로 해석하기 위해 소프트맥스 함수 결과에 \log 값을 취한 연산
 - 소프트맥스는 기울기 소멸 문제에 취약하기 때문에 로그 소프트맥스 사용
- 출력층에 가까울수록 원래 형태를 찾아볼 수 없고 이미지 특징들만 전달되는 것을 확인할 수 있음


그래프 합성곱 네트워크

- 그래프 데이터를 위한 신경망

그래프란

- 그래프는 방향성이 있거나 없는 에지로 연결된 노드의 집합

▼ 그림 5-50 그래프

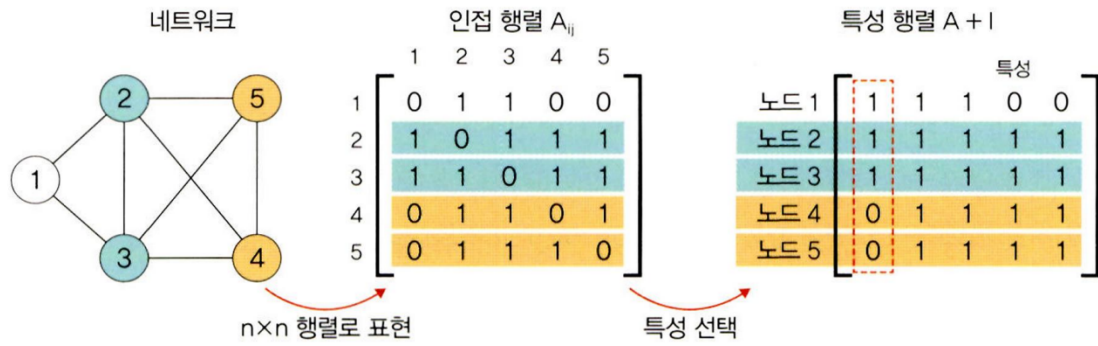


- 노드 : 파란 색 원, 원소를 의미
- 에지 : 두 노드를 연결한 선, 결합 방법 등을 의미

그래프 신경망

- 그래프 구조에서 사용하는 신경망
- 1단계 : 인접 행렬 → 노드 n 개를 $n \times n$ 행렬로 표현 → 컴퓨터가 이해하기 쉽게 그래프로 표현
- 2단계 : 특성 행렬 → 인접 행렬만으로는 특성 파악이 어려워 단위 행렬을 적용. 각 입력 데이터에서 이용할 특성을 선택. 각 행은 선택된 특성에 대해 각 노드가 갖는 값을 의미.

▼ 그림 5-51 특성 행렬⁵

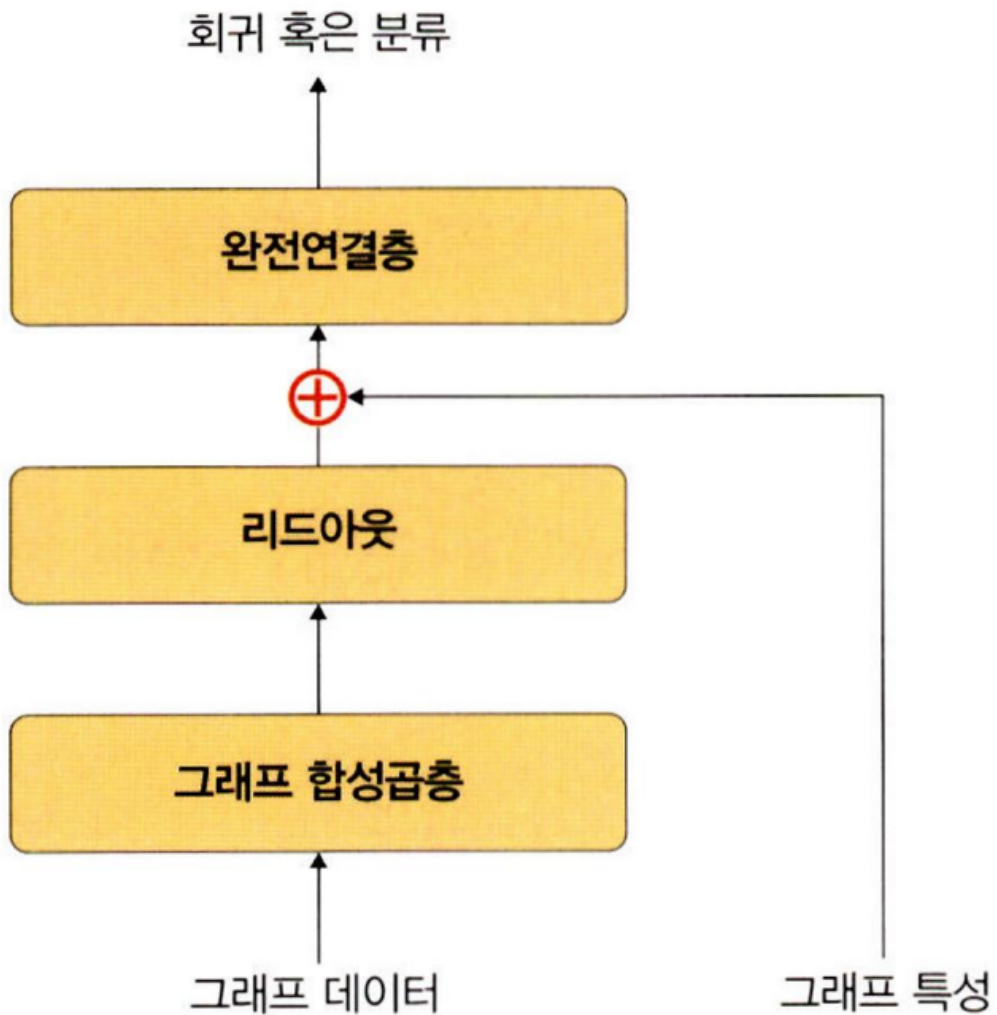


- 특성 행렬 과정을 거쳐 그래프 특성이 추출됨

그래프 합성곱 네트워크

- 이미지에 대한 합성곱을 그래프 데이터로 확장한 알고리즘

▼ 그림 5-52 그래프 합성곱 네트워크



- 리드 아웃 : 특성 행렬을 하나의 벡터로 변환하는 함수
 - 전체 노드의 특성 벡터에 대해 평균을 구하고 그래프 전체를 표현하는 하나의 벡터 생성
- GCN에서 가장 중요한 부분 → 그래프 합성곱층
 - 그래프 합성곱층을 이용한 그래프 형태의 데이터는 행렬 형태의 데이터로 변환됨
→ 딥러닝 알고리즘 적용 가능 (기존 그래프 형태의 데이터 → 딥러닝 알고리즘 적용 X)
 - GCN 활용하는 곳

- 관계 네트워크
- 학술 연구에서 인용 네트워크
- 3D Mesh